Implementasi Pipeline Audio Processing Untuk Klasifikasi Suara Hewan

Laporan Mini Project MII212405 - Pengenalan Pola KOM

Anders Emmanuel Tan
Departemen Ilmu Komputer dan Elektronika
24/541351/PA/22964

Farsya Nabila Tori
Departemen Ilmu Komputer dan Elektronika
24/543855/PA/23113

Fikar Adi Nugraha
Departemen Ilmu Komputer dan Elektronika
24/538520/PA/22856

Keyne Elvaretta Zulfa Arafah
Departemen Ilmu Komputer dan Elektronika
24/533391/PA/22572

Khoirul Adib Fairuza
Departemen Ilmu Komputer dan Elektronika
24/534902/PA/22688

I. Pendahuluan

A. Latar Belakang

Suara adalah fenomena fisik dalam bentuk gelombang akustik yang diproduksi oleh organ pada makhluk hidup yang berartikulasi dan yang berperan sebagai medium dalam penyampaian informasi terkait keanekaragaman dalam alam liar Penar et al., 2020. Dalam bioakustik, identifikasi suara hewan berperan vital dalam pemantauan ekologis dan konservasi spesies. Namun, pemantauan atau monitoring manual mengalami tantangan berupa batasan waktu dan inefisiensi dalam penanganan volume data yang besar Jurafsky and Martin, 2026. Maka dari itu, pengembangan sistem klasifikasi yang terotomatisasi menjadi solusi esensial untuk monitoring lingkungan yang dinamis melalui pendekatan komputasional yang lebih konsisten dan akurat.

Prinsip-prinsip yang mendasari Automatic Speech Recognition (ASR) menyediakan fondasi teoritis yang relevan dalam mentransformasi sinyal analog menjadi representasi digital melalui digitasi yang melibatkan mekanisme sampling dan kuantisasi Ahlawat et al., 2025. Meski ASR dirancang untuk mengenali ucapan manusia, prinsip-prinsip pengolahannya, seperti resampling, ekstraksi fitur akustik, dan normalisasi sinyal dapat diadaptasi untuk keperluan klasifikasi suara hewan. Dalam konteks bioakustik, tantangan utamanya adalah variabilitas sinyal yang tinggi akibat suara lingkungan sehingga dibutuhkan sistem yang robust untuk dapat menganalisis pola yang diperlukan Blumstein et al., 2011; Owino and Shibwabo, 2025.

Proyek ini berfokus pada klasifikasi lima jenis suara hewan, yakni burung, macaque, giant otter, orca, dan zebra finch. Dengan menggunakan teknik, seperti resampling dan normalisasi amplitudo, sistem dapat mengeliminasi bias yang diakibatkan oleh jarak mikrofon atau variasi volume sehingga sistem dapat secara akurat mengidentifikasi pola komunikasi biologis hewan.

B. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah adalah sebagai berikut:

1) Bagaimana merancang pipeline preprocessing audio yang mampu menghasilkan sinyal yang konsisten dari data yang heterogen?
2) Bagaimana hasil dari mengekstraksi fitur gabungan antara MFCC, Mel Spectrogram, dan fitur temporal?
3) Bagaimana performa algoritma klasifikasi SVM, Random Forest, KNN, Naive Bayes, Decision Tree, dan MLP dalam mengklasifikasikan lima jenis suara hewan berdasarkan fitur yang telah diekstraksi?

C. Batasan Masalah

Fokus pada 5 kelas hewan (birds, macaque, giant_otter, orca, zebra_finch), menggunakan durasi tetap 3 detik, dan sampling rate standar 22050 Hz.

D. Tujuan

Membangun sistem klasifikasi suara hewan yang mampu mengenali pola audio secara otomatis menggunakan pendekatan Machine Learning.

II. Metodologi

A. Digaram Alir Sistem

Diagram alir sistem pada penelitian ini dapat dilihat pada Gambar 1. Proses dimulai dengan akuisisi data audio dari dataset yang telah dipilih, kemudian dilanjutkan dengan tahapan prapemrosesan untuk menyiapkan data agar siap untuk diekstraksi fiturnya. Setelah fitur diekstraksi, data akan digunakan untuk membangun model klasifikasi suara hewan menggunakan algoritma machine learning.

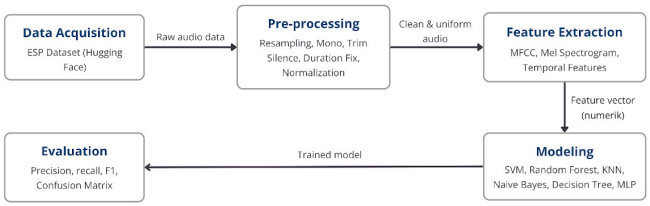

Gambar 1. Diagram alir tahapan pipeline audio processing

Tahapan terakhir adalah evaluasi model untuk mengukur kinerja dan efektivitasnya dalam mengklasifikasikan suara hewan berdasarkan dataset yang telah disiapkan.

B. Dataset dan Akuisisi Data

Dataset yang digunakan diperoleh dan diakses melalui platform Hugging Face cgeorgiaw, n.d. Dataset ini terdiri dari rekaman suara hewan dengan jumlah sampel yang bervariasi pada setiap kelas.

Pada kondisi awal, dataset bersifat tidak seimbang (imbalanced) dengan distribusi sebagai berikut: birds (686 sampel), macaque (7.290 sampel), giant otter (441 sampel), orca (594 sampel), dan zebra finch (3.410 sampel).

Untuk mengatasi ketidakseimbangan data, masing-masing kelas diambil sebanyak 400 sampel sehingga diperoleh dataset yang seimbang (balanced) dengan total 2.000 sampel. Pendekatan ini dilakukan untuk menghindari bias model terhadap kelas dengan jumlah data yang lebih besar.

Dataset yang digunakan berasal dari berbagai sumber dengan karakteristik yang beragam. Durasi rekaman bervariasi mulai dari sekitar 0,02 detik hingga lebih dari 30 detik. Selain itu, sampling rate audio juga tidak seragam, berkisar antara 24 kHz hingga 96 kHz tergantung pada sumber dataset.

Penelitian ini hanya menggunakan kolom audio yang berisi data waveform dan sampling rate.

C. Prapemrosesan Audio

1) Resampling: Tahapan ini dilakukan dengan menyeragamkan frekuensi sampling seluruh data audio ke nilai standar, yakni 22050 Hz untuk menyeimbangkan kualitas informasi dan efisiensi komputasi. Berdasarkan teorema Nyquist, sampling rate minimal harus 2 kali lipat dari frekuensi tertinggi (2f) agar suatu gelombang suara dapat direkonstruksi melalui pengambilan sampel pada titik puncak dan titik lembahnya. Apabila standar audio CD sebesar 44100 Hz digunakan untuk mencakup ambang pendengaran manusia hingga 20 kHz (20000 Hz), frekuensi yang lebih rendah dapat dipilih untuk mengoptimalkan pemrosesan audio tanpa kehilangan informasi penting.

Untuk proyek ini, digunakan 22050 Hz (tepat setengah standar CD) yang memungkinkan penangkapan informasi akustik pada rentang 0–11025 Hz yang mencakup sebagian besar pola frekuensi penting pada suara hewan, seperti burung, orca, dan berang-berang. Frekuensi yang melebihi ambang batas tersebut cenderung kurang informatif sehingga pengabaiannya dapat mengefisiensikan proses. Langkah ini penting untuk menjamin konsistensi resolusi temporal agar perbandingan antarsampel bersifat objektif.

2) Stereo ke Mono: Tahapan ini merupakan penggabungan saluran audio stereo (kiri-kanan), yang bertujuan agar manusia dapat merasakan dimensi ruang suara yang bergerak dari kiri ke kanan, menjadi mono (satu saluran tunggal) dengan cara merata-ratakan sinyalnya. Konversi ini dilakukan karena analisis pola akustik berfokus pada kandungan frekuensi sinyal itu sendiri, bukan pada posisi spasial sumber suara. Misal, saat kalkulasi fitur, seperti Mel-Frequency Cepstral Coefficients (MFCC) pada dua saluran sekaligus hanya akan menduplikasi pekerjaan dan memperlambat proses tanpa memberikan akurasi tambahan pada model.

3) Trim Silence: Saluran audio mono selanjutnya akan dibersihkan deraunya (noise removal) dengan cara menghapus atau trim bagian hening di awal dan akhir rekaman melalui deteksi ambang batas amplitudo tertentu. Analisis bagian sinyal yang representatif terhadap aktivitas vokal hewan dapat dilakukan oleh sistem dengan lebih fokus karena segmen yang tidak memiliki informasi suara dieliminasi. Hal ini juga meminimalkan beban komputasi serta menghindari bias akibat jeda kosong dalam dataset.

4) Filter Durasi: Filter durasi diimplementasikan untuk memastikan sampel audio memiliki informasi akustik yang memadai untuk analisis yang robust. Sampel yang kurang dari 3 detik setelah dilakukan trimming dikeluarkan dari dataset karena suara yang terlalu pendek mungkin tidak memiliki pola yang cukup, seperti fitur fonetik dan prosodik untuk dipelajari oleh model. Namun, sebagai langkah preventif, dilakukan pengecekan statistik dataset. Apabila jumlah sampel dengan durasi di atas 3 detik tidak mencukupi, ambang batas durasi akan diturunkan secara adaptif, lalu dilakukan tahapan preprocessing selanjutnya untuk menjaga kuantitas korpus data training.

5) Fixing Duration (Padding/Truncation): Untuk memenuhi kebutuhan teknis dari proses modeling dengan Machine Learning (ML), semua sinyal audio harus distandardisasi ke panjang temporal yang tetap, yaitu tepat 3 detik dengan sample rate 22050 Hz. Hal ini penting karena model Machine Learning membutuhkan input dengan dimensi yang seragam agar proses pelatihan dapat berjalan secara konsisten.

Pada kasus ketika sinyal hasil pemotongan (trim) melebihi target durasi, audio akan ditrunkasi untuk mempertahankan pola vokal yang paling representatif. Sebaliknya, durasi sinyal yang kurang dari 3 detik akan menerima zero-padding dengan penambahan nilai nol pada akhir sekuens audio sesuai dengan panjang yang diinginkan tanpa membuat artefak akustik buatan atau distorsi yang muncul akibat proses manipulasi digital yang tidak sempurna. Pendekatan ini memungkinkan normal-

isasi durasi sinyal sambil mempertahankan integritas dari komponen frekuensi originalnya.

6) Normalisasi Amplitudo: Tahapan akhir dari preprocessing ini adalah normalisasi amplitudo, yakni proses yang dibutuhkan karena adanya fakta bahwa intensitas dari suara, yakni loudness, bergantung pada amplitudo getaran. Sebab variasi dari lingkungan perekaman, misal seberapa dekat posisi mikrofon saat merekam, dapat menyebabkan inkonsistensi pada level volume. Tahap ini menskalakan sinyal akustik atau nilai gelombang audio ke rentang yang terstandardisasi, biasanya di antara -1 dan 1 inklusif [-1, 1], untuk memastikan loudness tidak bias ke model.

D. Ekstraksi Fitur

1) Mel-Frequency Cepstral Coefficient (MFCC): Pada tahapan ini, peneliti mengekstrak fitur Mel-Frequency Cepstral Coefficient (MFCC) dari audio yang telah diprapproses pada bagian sebelumnya. Untuk mengekstrak fitur tersebut, diperlukan beberapa langkah. Pertama, signal audio akan dipecah-pecah menjadi beberapa frame. Pada kasus ini, peneliti menggunakan metode windowing Hann Window yang diaplikasikan secara default oleh library yang digunakan oleh peneliti. Kemudian, ia akan ditransformasikan ke domain frekuensi menggunakan STFT dan diteruskan ke filter berbentuk segitiga. Setelah itu, algoritma akan mengambil logaritma dari energi filter bank dan mengaplikasikan DCT untuk mendapatkan koefisien MFCC akhir.

Implementasi MFCC yang digunakan peneliti memanfaatkan library librosa untuk seluruh 2000 sampel dataset. Untuk setiap sampel, sebanyak 40 koefisien MFCC telah diekstrak, beserta turunan delta dan delta-delta. Nilai mean dan standar deviasi untuk seluruh frame akan dikalkulasi untuk dimasukan ke representasi fitur vektor akhir yang dimasukan di model machine learning pada tahapan selanjutnya. Peneliti menggunakan metode fitur representasi ini karena ia telah terbukti untuk dapat merepresentasikan audio menjadi gambaran yang padat yang menangkap karakteristik-karakteristik berbeda pada setiap audio suara hewan.

2) Mel Spectogram Statistic: Selain MFCC, peneliti juga menggunakan fitur Mel Spectrogram untuk merepresentasikan audio dari dataset yang telah diprapproses. Representasi ini mentransformasikan skala Hertz yang bersifat linear menjadi skala Mel. Serupa dengan MFCC, representasi ini diekstrak dengan pertama mendapatkan frame dari audio dan mentransformasikan setiap frame menggunakan STFT yang diteruskan ke filter berbentuk segitiga berskala Mel. Namun, ia tidak mengaplikasikan DCT seperti pada MFCC, akan tetapi, ia menggunakan distribusi energi penuh dari setiap frame sehingga ia bertindak sebagai fitur pelengkap bagi MFCC. Selain itu, energi-energi yang dihasilkan akan dikonversi ke skala desibel menggunakan transformasi log untuk mengkompresi rentang dinamis nilai energi, yang kemudian akan diambil nilai rata-rata dan standar deviasinya.

3) Fitur Temporal: Peneliti juga akan mengekstrak beberapa fitur pada domain waktu untuk mengkarakterisasi ciri-ciri audio dari waktu ke waktu. Pada kasus ini, enam fitur temporal yang diekstrak adalah:

- Zero Crossing Rate (ZCR): fitur ini mengukur tingkat signal audio berubah tanda. Dengan kata lain, ia menghitung seberapa sering gelombang audio melalui amplitude nol.
- Root Mean Square (RMS) Energy: fitur ini mengukur rerata keras atau energi dari sinyal audio untuk setiap frame.
- Spectral Centroid: fitur ini merepresentasikan titik pusat massa dimana energi sinyal tersebut terkonsentrasi.
- Spectral Bandwidth: fitur ini mengukur sebaran frekuensi disekitar spectral centroid.
- Spectral Rolloff: fitur ini mengukur frekuensi di mana persentase tertentu dari total energi sinyal berada dibawah frekuensi tersebut.
- Spectral Flatness: fitur ini mengukur tingkat kemiripan spektrum audio dengan pure tone dibandingkan white noise.

Seperti pada dua metode representasi sebelumnya, fitur tersebut diekstrak dan diagregasikan menggunakan nilai rerata dan standar deviasi seluruh frame audio menggunakan bantuan library librosa. Fitur-fitur tersebut dipakai di studi ini karena ia menangkap dimensi suara hewan yang berbeda dibanding MFCC dan Mel Spectogram. Dengan menggabungkan ketiga set fitur menjadi satu vektor fitur, classifier yang digunakan pada tahap berikutnya akan mendapatkan representasi yang komprehensif dan multi-dimensi untuk setiap suara hewan.

E. Permodelan

1) Input Vektor Akhir: Pada tahap ini, vektor fitur yang telah terekstraksi pada tahap sebelumnya akan digunakan sebagai input untuk melatih 6 algoritma klasifikasi. Vektor fitur akhir untuk setiap sampel berupa penggabungan tiga kelompok fitur secara horizontal dengan meng-concatenate antara fitur MCFF (240 dimensi), fitur Mel Spectrogram (256 dimensi), dan fitur temporal (12 dimensi), sehingga menghasilkan representasi berdimensi 508 per sampel.

2) Normalisasi Fitur: Setelah tahap input vektor akhir, semua fitur dinormalisasi menggunakan StandardSCaler dan library scikit-learn. StandardScaler bekerja dengan cara mengurangi nilai rata-rata(mean) kemudian membaginya dengan standar deviasi untuk setiap dimensi fitur, sehingga menghasilkan distribusi dengan mean p dan standar deviasi 1. Proses dit scaler hanya dioperasikan pada data latih (X_train_features) kemudian hasilnya diterapkan secara terpisah ke data uji (X_test_features) untuk mencegah terjadinya data leakage.

3) Algoritma Klasifikasi: Algoritma klasifikasi yang digunakan untuk membandingkan performa meliputi:

1) Support Vector Machine (SVM)
SVM adalah algoritma supervised learning yang berfokus pada klasifikasi dan regresi dengan mencari hyperplane optimal yang memaksimalkan margin antar kelas. SVM menggunakan fungsi kernel sehingga mampu memetakan data ke ruang berdimensi lebih tinggi Suthaharan, 2016.
2) Random Forest
Random Forest merupakan algoritma ensemble learning yang menggabungkan banyak decision tree untuk meningkatkan performa klasifikasi. Setiap pohon dibangun berdasarkan subset data dan fitur yang dipilih secara acak, kemudian hasil akhir ditentukan melalui mekanisme voting Biau and Scornet, 2015.
3) K-Nearest Neighbors (KNN)
KNN adalah algoritma yang melakukan klasifikasi berdasarkan kedekatan jarak antara data uji dan data latih. Kelas suatu data ditentukan berdasarkan mayoritas label dari k tetangga terdekat Peterson, 2009.
4) Naive Bayes Gaussian
Naive Bayes Gaussian merupakan algoritma klasifikasi probabilistik yang didasarkan pada Teorema Bayes dengan asumsi independensi antar fitur. Data numerik diasumsikan mengikuti distribusi normal dalam varian Gaussian Zhang, 2004.
5) Decision Tree
Decision Tree membangun model dalam bentuk struktur pohon melalui proses pembagian data secara rekursif berdasarkan fitur tertentu. Setiap node merepresentasikan pengujian atribut, cabang menunjukkan hasil keputusan, dan daun merepresentasikan kelas akhir. Proses ini bertujuan meningkatkan homogenitas data menggunakan kriteria seperti information gain atau gini index Rokach and Maimon, 2005.
6) Multi-Layer Perceptron (MLP)
MLP adalah Artificial Neural Network yang terdiri dari lapisan input, hidden layer, dan output. MLP memanfaatkan bobot serta fungsi aktivasi untuk mempelajari hubungan non-linear dalam data Surya, 2021.

F. Evaluasi Model

Evaluasi model terbagi dalam dua tahap yang terpisah. Tahap pertama adalah validasi menggunakan Stratified K-Fold Cross Validation dengan k=5 pada data latih, sedangkan tahap kedua adalah evaluasi final pada data uji.

1) Validasi: Pada tahap validasi, Stratified K-Fold digunakan agar proporsi tiap kelas terjaga secara merata di setiap fold. Setiap model dicatat nilai akurasi rata-rata pada data latih, akurasi rata-rata validasi beserta standar deviasinya (*valaccuracystd*), serta selisih antara keduanya. Selisih antara akurasi latih dan validasi akan dijadikan indikasi potensi overfitting pada model tersebut.

G. Evaluasi Final

Pada tahap evaluasi final, semua model di-fit ulang menggunakan seluruh data latih, kemudian diuji pada data uji. Metrik yang digunakan pada tahap ini meliputi akurasi keseluruhan (accuracy score), precision, recall, serta F1-score per kelas. Selain itu, perbandingan antara akurasi validasi dan akurasi test dilakukan untuk mendeteksi apakah estimasi validasi terlalu optimis atau sebaliknya. Gap yang melebihi 0,05 antara akurasi validasi dan akurasi test akan dianggap sebagai indikasi ketidakkonsistenan yang perlu dicurigai.

III. Hasil dan Pembahasan

A. Analisis Sinyal Audio

Tabel I
Sample Rate dan Panjang Sinyal Tiap Kelas

Kelas	Sample Rate (Hz)	Jumlah Sampel	Durasi (detik)
birds	44100	110336	5.00
macaque	24414	13573	0.62
giant_otter	96000	5120	0.23
orca	44100	88200	4.00
zebra_finch	44100	4673	0.21

1) Kondisi Awal Data Audio: Dapat dilihat di tabel I, sebelum tahap preprocessing, kondisi awal sinyal audio sangat heterogen. Sampling rate antar kelas bervariasi, mulai dari 24.414 Hz hingga 96.000 Hz. Bahkan setelah proses trim silence, panjang sinyal variasi juga masih menunjukkan variasi yang besar.

Tabel II
Ringkasan Distribusi Durasi Sinyal

Parameter	Nilai
Total sampel	2000
Durasi minimum (detik)	0.04
Durasi maksimum (detik)	9.40
Durasi rata-rata (detik)	1.96
Sampel > 3 detik	706
Sampel ≤ 3 detik	1294

2) Analisis Distribusi Durasi: Dapat dilihat di tabel II, sebelum proses padding dan truncation pada preprocessing, rata-rata durasi dataset adalah 1,96 detik degnan rentang antara 0,04 hingga 9,40 detik. Dari total 2000 sampel, hanya 706 sampel (35,3%) yang memiliki durasi di atas 3 detik.

Dengan demikian, ambang batas 3 detik akan menyebabkan hilangnya lebih dari 64% data. Seluruh kelas macaque tidak memenuhi ambang tersebut (0 dari 400 sampel), serta sebagian kelas giant otter dan zebra finch juga terbuang. Oleh karena itu, durasi target akan ditetapkan sebesar 2 detik karena rata-rata durasi adalah 1.96 detik sehingga sampel yang lebih pendek tidak akan

terlalu banyak padding-nya dan yang lebih panjang hanya akan dipotong sedikit.

Tabel III
Verifikasi Padding dan Truncation Sinyal

Label	Panjang Sinyal
giant_otter	44100 sampel (2.00 detik)
birds	44100 sampel (2.00 detik)
giant_otter	44100 sampel (2.00 detik)

3) Standarisasi Sinyal: Dapat dilihat di tabel III, setelah melalui tahap padding dan truncation pada tahap preprocessing, setiap sampel audio telah terstandarisasi menjadi sinyal mono dengan sampling rate 22.050 Hz dan durasi tetap 2 detik.

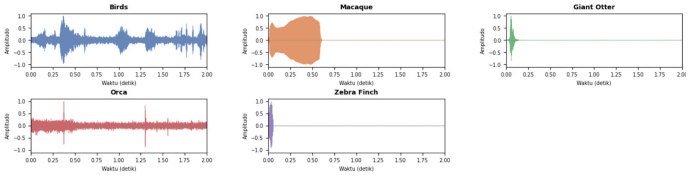

Gambar 2. Visualisasi Sinyal Audio Setelah Normalisasi Amplitudo

4) Normalisasi Amplitudo: Setelah proses normalisasi amplitudo, seluruh data sinyal audio memiliki nilai maksimum sebesar 1.0 dan nilai minimum yang mendekati -1.0 tergantung sampel yang dapat dilihat di Gambar 2. Hal ini mengindikasikan bahwa normalisasi peak-absolute telah berhasil menstandarkan level volume antar sampel tanpa mengubah bentuk gelombang aslinya.

B. Interpretasi Data

Tabel IV
Verifikasi Feature Extraction

Dataset	Jumlah Sampel	Jumlah Fitur
X_train_features	1600	508
X_test_features	400	508

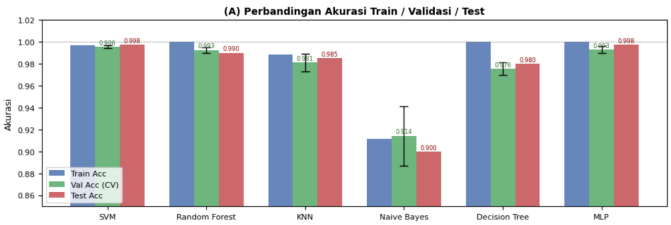

Gambar 3. Perbandingan Akurasi Train, Test, dan Validasi

1) Representasi Fitur: Vektor fitur akhir berdimensi 508 pada Tabel IV yang berasal dari concatenation MFCC, Mel Spectrogram, dan fitur temporal terbukti mampu merepresentasikan perbedaan akustik antarkelas secara efektif. Hal ini dibuktikan dengan tingginya performa seluruh model yang dapat dilihat pada Gambar 3, bahkan ketika menggunakan parameter default.

2) Pengaruh Standarisasi Durasi: Durasi sinyal yang sama (2 detik) berperan dalam menjaga konsistensi ekstraksi fitur. Fitur seperti MFCC dan Mel Spectrogram dihitung berbasis frame, kemudian diagregasikan menggunakan nilai rata-rata dan standar deviasi.

Tanpa standardisasi durasi, jumlah frame tiap sampel akan bervariasi, sehingga menghasilkan representasi fitur yang tidak sebanding. Oleh karena itu, panjang sinyal yang seragam akan menghasilkan sampel yang memiliki jumlah frame yang seragam, sehingga agregasi statistik dapat dibandingkan secara langsung.

3) Pengaruh Normalisasi Amplitudo: Normalisasi amplitudo berperan dalam menghasilkan pemisahan kelas yang lebih akurat. Tanpa normalisasi amplitudo, variasi volume akibat perbedaan jarak mikrofon atau keadaan perekaman dapat mempengaruhi fitur seperti RMS dan MFCC. Hal ini menyebabkan model berpotensi mempelajari perbedaan berdasarkan tingkat keras atau pelannya suara, bukan berdasarkan karakteristik akustik aslinya. Dengan normalisasi peak-absolute, bias tersebut dapat dihindari sehingga model lebih fokus pada pola frekuensi dan temporal.

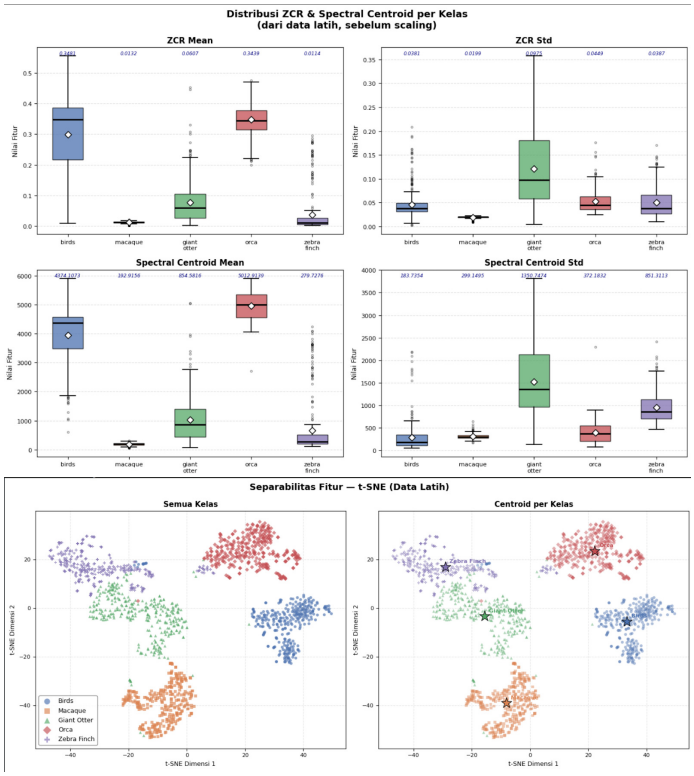

Gambar 4. Visualisasi Distribusi Fitur dan Separabilitas Antar Kelas

4) Separabilitas Akustik Antar Kelas: Perbedaan karakteristik akustik antar kelas menjadi faktor utama yang memperlancar proses klasifikasi. Setiap kelas membawa karakteristik yang mencolok yang tercermin dalam nilai zero crossing rate (ZCR), spectral centroid, serta distribusi energi pada Mel Spectogram yang berbeda antar

kelas. Tingginya separabilitas akustik pada Gambar 4 ini menjelaskan mengapa hampir semua model mampu mencapai akurasi di atas 98%.

C. Performa Klasifikasi

Seluruh model menghasilkan performa yang sangat tinggi, dengan akurasi validasi (CV) pada rentang antara 91,44% hingga 99,56%, serta akurasi test antara 90,00% hingga 99,75%. Berdasarkan Gambar V, SVM dan MLP

Tabel V
Hasil Validasi (Stratified 5-Fold CV) dan Perbandingan dengan Akurasi Test

Model	Train Acc	Val Acc	Std	Gap
SVM	0.9970	0.9956	±0.0015	0.0014
Random Forest	1.0000	0.9925	±0.0025	0.0075
KNN	0.9884	0.9812	±0.0081	0.0072
Naive Bayes	0.9117	0.9144	±0.0271	-0.0027
Decision Tree	1.0000	0.9756	±0.0057	0.0244
MLP	1.0000	0.9931	±0.0031	0.0069

Model	Val Acc (CV)	Test Acc	Gap
SVM	0.9956	0.9975	-0.0019
MLP	0.9931	0.9975	-0.0044
Random Forest	0.9925	0.9900	0.0025
KNN	0.9812	0.9850	-0.0038
Decision Tree	0.9756	0.9800	-0.0044
Naive Bayes	0.9144	0.9000	0.0144

menjadi model paling unggul dengan akurasi tes 99,75%, disusul Random Forest (99,00%), KNN (98,50%), dan Decision Tree (98,00%). Naive Bayes menduduki posisi terendah dengan akurasi 90,00% karena asumsi independensi antarfitur yang tidak sepenuhnya terpenuhi pada data audio yang memiliki korelasi tinggi antarkoefision MFCC.

Seluruh model menghasilkan gap validasi-test yang relatif kecil(di bawah 0,02) yang mengindikasikan bahwa estimasi performa dari CV konsisten degnan performa sesungguhnya pada data baru(data tes). Selain itu, hal ini juga mengonfirmasi tidak adanya data leakage yang dalam pipeline.

IV. Penutup

A. Kesimpulan

Berdasarkan hasil implementasi klasifikasi suara hewan, dapat disimpulkan bahwa sistem yang dibangun dapat melakukan klasifikasi dengan performa yang sangat baik. Proses preprocessing yang meliputi resampling, konversi stereo ke mono, trimming silence, standarisasi durasi, serta normalisasi amplitudo terbukti efektif dalam menghasilkan data audio yang siap untuk dianalisis.

Ekstraksi fitur yang berupa gabungan MFCC, Mel Spectrogram, dan fitur temporal menghasilkan representasi vektor berdimensi 508 mampu menangkap karakteristik akustik secara komprehensif. Hal ini sangat berkontribusi terhadap kualitas performa model klasifikasi.

Seluruh algoritma yang digunakan menunjukkan hasil yang sangat baik, degan akurasi validasi dan pengujian yang tinggi ditambah juga dengan gap validasi-test yang kecil, menandakan model memiliki generalisasi yang baik dan tidak mengalami overfitting. Model SVM dan MLP menjadi model terbaik dengan akurasi 99,75%, sementara mode Naive Bayes menghasilkan performa terendah akibat asumsi independensi fitur yang tidak sepenuhnya terpenuhi.

B. Saran

Terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya. Pertama, penggunaan dataset yang lebih banyak dan beragam dapat meningkatkan performa model, terutama ketika menghadapi kondisi lingkungan yang lebih kompleks dan bervariasi.

Kedua, eksplorasi metode ekstraksi fitur lain, seperti deep learning berbasis spectrogram, dapat menjadi alternatif untuk meningkatkan performa tanpa bergantung pada fitur yang dibuat secara manual.

Terakhir, karena pada penelitian ini sebagian besar model masih diberikan parameter default, tuning hyperparameter pada setiap model klasifikasi dapat dilakukan untuk meningkatkan performa mereka.

Daftar Pustaka

Ahlawat, H., Aggarwal, N., & Gupta, D. (2025). Automatic speech recognition: A survey of deep learning techniques and approaches. International Journal of Cognitive Computing in Engineering, 6, 201–237. https://doi.org/https://doi.org/10.1016/j.ijcce.2024.12.007

Biau, G., & Scornet, E. (2015). A random forest guided tour. https://arxiv.org/abs/1511.05741

Blumstein, D. T., Mennill, D. J., Clemins, P., Girod, L., Yao, K., Patricelli, G., Deppe, J. L., Krakauer, A. H., Clark, C., Cortopassi, K. A., Hanser, S. F., McCowan, B., Ali, A. M., & Kirschel, A. N. G. (2011). Acoustic monitoring in terrestrial environments using microphone arrays: Applications, technological considerations and prospectus. Journal of Applied Ecology, 48(3), 758–767. https://doi.org/https://doi.org/10.1111/j.1365-2664.2011.01993.x

cgeorgiaw. (n.d.). Animal-sounds [Hugging Face dataset].

Jurafsky, D., & Martin, J. H. (2026). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition, with language models (3rd) [Online manuscript released January 6, 2026]. https://web.stanford.edu/~jurafsky/slp3/

Owino, G., & Shibwabo, B. (2025). Noise-resilient bioacoustics feature extraction methods and their implications on audio classification performance: Systematic review. JMIR Biomed Eng, 10, e80089. https://doi.org/10.2196/80089

Penar, W., Magiera, A., & Klocek, C. (2020). Applications of bioacoustics in animal ecology. Ecological Complexity, 43, 100847. https://doi.org/https://doi.org/10.1016/j.ecocom.2020.100847

Peterson, L. (2009). K-nearest neighbor. Scholarpedia, 4, 1883. https://doi.org/10.4249/scholarpedia.1883

Rokach, L., & Maimon, O. (2005). Decision trees. In O. Maimon & L. Rokach (Eds.), Data mining and knowledge discovery handbook (pp. 165–192). Springer US. https://doi.org/10.1007/0-387-25465-X_9

Surya, A. (2021). Machine learning and ensemble approach onto predicting heart disease. https://arxiv.org/abs/2111.08667

Suthaharan, S. (2016, January). Support vector machine. https://doi.org/10.1007/978-1-4899-7641-3_9

Wahyono. (n.d.). Introduction to automatic speech recognition.

Zhang, H. (2004). The optimality of naive bayes. Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference, FLAIRS 2004, 2.